

Relatório Técnico – KNN (*K-Nearest-Neighbors*)

Aluno: Marco Antonio Maia

Matrícula: 202220256

Disciplina: GCC128 – Inteligência Artificial

Professor: Ahmed Ali Abdalla Esmin

1. Definição e Apresentação da Base de Dados

O Dataset Iris

O conjunto de dados Iris, introduzido por Ronald Fisher em 1936, constitui um *benchmark* clássico em *machine learning*, frequentemente utilizado para tarefas de classificação supervisionada.

- **Composição:** 150 amostras igualmente distribuídas entre três espécies do gênero *Iris* (*setosa*, *versicolor* e *virginica*).
- **Atributos:** 4 atributos numéricos contínuos (comprimento e largura da sépala; comprimento e largura da pétala, em cm).
- **Qualidade:** Instâncias perfeitamente categorizadas, sem valores faltantes ou inconsistentes.
- **Equilíbrio:** Distribuição balanceada (50 amostras por classe), eliminando a necessidade de técnicas de reamostragem.

A relevância científica desta base reside em suas propriedades estatísticas bem comportadas e na separabilidade parcial das classes. Enquanto a *Iris setosa* é linearmente separável das demais, a *versicolor* e a *virginica* apresentam regiões de sobreposição em seu espaço de características, criando um desafio interessante para classificadores.

O Algoritmo KNN

O algoritmo KNN (*K-Nearest Neighbors*) é uma técnica de aprendizado supervisionado baseada em instâncias. Sua principal característica é a ausência de uma fase explícita de treinamento: o algoritmo armazena todo o conjunto de treinamento e realiza as previsões com base na similaridade entre as instâncias.

Para classificar uma nova amostra, o KNN identifica os k exemplos mais próximos no espaço de características e determina a classe mais frequente entre eles.

- **Escolha de k:** Valores baixos tornam o modelo sensível a ruídos; valores altos suavizam excessivamente as fronteiras de decisão.
- **Métrica de Proximidade:** Distância Euclidiana, definida matematicamente como:

$$d(p, q) = \sqrt{\sum_{i=1}^n (p_i - q_i)^2}$$

Onde p e q são vetores n-dimensionais representando duas amostras, e p_i, q_i são os valores dos atributos na i-ésima dimensão.

2. Comparação entre as Aplicações

Neste trabalho, foram implementadas duas abordagens distintas para o algoritmo KNN: uma versão manual (*hardcore*) e uma versão baseada na biblioteca *scikit-learn*.

Detalhes das Implementações

- **Implementação Hardcore (Manual):**
 - Desenvolvida do zero em Python (*numpy* e *pandas*).
 - Cálculo explícito da distância euclidiana e ordenação manual.
 - **Vantagem:** Total controle e transparência do código (ideal para fins educacionais).
 - **Limitação:** Baixo desempenho em grandes volumes de dados por falta de estruturas otimizadas.
- **Implementação Scikit-learn:**
 - Utilizou a classe *KNeighborsClassifier* (implementada em Cython).
 - Uso de estruturas eficientes como *KD-Trees* e *Ball Trees*.
 - **Vantagem:** Alta otimização, velocidade e abstração de complexidade.
 - **Limitação:** Menor flexibilidade para personalizações específicas do algoritmo.

Matriz Comparativa de Desempenho

Critério	Implementação Hardcore (Manual)	Implementação Scikit-learn
Tempo de Execução	Significativamente maior (mais lento)	Significativamente menor (otimizado)
Estrutura de Dados	Busca linear simples	Algoritmos de árvore (<i>KD-Tree</i> / <i>Ball Tree</i>)

Métricas (k = [1, 3, 5, 7])	Resultados consistentes e idênticos	Resultados consistentes e idênticos
Escalabilidade	Baixa (suscetível a gargalos)	Alta (focada em produção)
Objetivo Principal	Validação lógica e aprendizado	Aplicação prática e análise de resultados

3. Resultados e Limitações

Resultados Obtidos

Os experimentos demonstraram que o algoritmo KNN é altamente eficaz para a classificação do dataset Iris, alcançando excelentes taxas de acurácia.

- Separação Perfeita:** As matrizes de confusão confirmaram que a classe *Iris-setosa* é totalmente separável das demais.
- Zonas de Sombra:** As classes *Iris-versicolor* e *Iris-virginica* apresentaram erros mútuos de classificação devido à sobreposição natural de seus atributos.
- Eficiência:** A versão *scikit-learn* superou a manual em tempo de execução em todos os valores de k testados.

Limitações Identificadas

- Dependência do Valor de k:** O ajuste do hiperparametro k impacta diretamente o viés e a variância do modelo.
- Escalabilidade Computacional:** A versão *hardcore* possui complexidade de busca $O(n^2)$, tornando-a inviável para grandes bancos de dados.
- Sensibilidade à Escala:** A distância euclidiana é sensível à escala dos atributos. Embora o dataset Iris não tenha exigido normalização, bases com escalas distintas demandam pré-processamento (como *MinMaxScaler* ou *StandardScaler*).
- Sobreposição de Classes:** O limite de acurácia máxima do dataset é ditado pela sobreposição biológica entre *versicolor* e *virginica*, independente da otimização do código.

Considerações Finais

O KNN se provou um algoritmo simples, robusto e perfeitamente aplicável ao conjunto de dados Iris. Para o ecossistema de desenvolvimento real, a implementação via **scikit-learn** continua sendo a escolha padrão devido à sua eficiência e escalabilidade, reservando a abordagem **hardcore** para consolidação teórica e auditoria de código.